

Методические указания к лабораторной работе

Тема № 1: Точечные оценки параметров методом моментов.

Цель работы – научиться генерировать выборки с заданными параметрами и определять точечные оценки параметров выборок методом моментов.

Реализация нахождения точечных оценок на сгенерированной выборке

Пример. Найдём точечные оценки параметров для выборок с нормальным законом распределения, показательным законом распределения, биномиальным законом распределения. Теоретические моменты для указанных распределений имеют вид: μ , σ , $1/\lambda$, np .

Сгенерируем выборки размером 500 со следующими параметрами:

```
> set.seed(0)
```

```
> x1=rnorm(500, 15, 34)
```

```
> x2=rexp(500,0.5)
```

```
> x3=rbinom(500,20,0.6)
```

```
set.seed(0)
```

```
x1=rnorm(500, 15, 34)
```

```
x2=rexp(500,0.5)
```

```
x3=rbinom(500,20,0.6)
```

```
str(x1)
```

```
##  num [1:500] 57.94 3.91 60.21 58.26 29.1 ...
```

```
str(x2)
```

```
##  num [1:500] 1.5106 0.1232 0.7394 2.4526 0.0542 ...
```

```
str(x3)
```

```
##  int [1:500] 11 12 14 8 11 13 14 14 11 16 ...
```

Найдём оценки неизвестных параметров

Для нормального закона распределения:

```
> a=mean(x1); a
```

```
> si=sd(x1); si
```

```
a=mean(x1); a
```

```
## [1] 14.9932
```

```
si=sd(x1); si
## [1] 33.64691
```

Для показательного закона распределения:

```
> lam=1/mean(x2); lam
```

```
lam=1/mean(x2); lam
## [1] 0.4780344
```

Для биномиального закона распределения:

```
> p=mean(x3)/20; p
```

```
> n=mean(x3)/0.6; n
```

```
p=mean(x3)/20; p
## [1] 0.6067
n=mean(x3)/0.6; n
## [1] 20.22333
```

Задание на самостоятельную работу:

1. Сгенерировать выборки с заданными параметрами (см. таблицу 1);
2. Оценить параметры методом моментов;
3. Проанализировать результаты и оформить их в виде отчета.

Таблица 1 Варианты заданий (n – порядковый номер в списке группы)

	1-10	11-20	21-30
НЗР	$(600+4n),$ $2+2n, 3+3n$	$(400+4n),$ $10+3n, 3+3n$	$(700+4n),$ $15+2n, 3+3n$
ПЗР	$600, 1+n$	$400, 3+n$	$700, 5+n$
БЗР	$600, 20+n, 0.6$	$500, 20+n, 0.7$	$700, 20+n, 0.8$

Тема № 2: Сравнение способов оценивания

Целью лабораторной работы является изучение трех способов статистического оценивания.

Лабораторная работа направлена на:

— изучение трех способов оценивания (три оценки):

1. Оценка, полученная методом моментов

$$\widehat{a1} = \frac{2}{n} * \sum_{i=1}^n x_i,$$

где n – количество независимых испытаний случайной величины X , x_i – значение случайной величины в i -ом испытании.

2. Оценка, полученная методом максимального правдоподобия

$$\widehat{a2} = \frac{n+1}{n} * MAXx_i,$$

где n – количество независимых испытаний случайной величины X , $MAXx_i$ – максимальное значение случайной величины.

3. Оценка, полученная методом порядковых статистик

$$\widehat{a3} = 2 * \widehat{x_{0.5}},$$

где $\widehat{x_{0.5}}$ – выборочная квантиль порядка 0,5, то есть выборочная медианна.

— получение навыков вычисления оценки максимального правдоподобия; медианной и суммарной оценок в R Studio;

— получение навыков вычисления характеристик разброса для оценок в R Studio;

— получение навыков сравнения трех методов оценивания.

Реализация нахождения оценок на сгенерированной выборке

Создадим 20 выборок с $n=10$, распределенной по НЗР:

```
```{r}
n <- 10
varCount <- 20
foo = rnorm
```

```
xs <- foo (n* varCount)
M <- matrix (xs , varCount , n)
```

```

Результат сгенерированных выборок:

| Untitled1* x M x | | | | | | | | |
|------------------|-------------|------------|------------|-------------|--------------|--------------|--------------|----|
| Filter | | | | | | | | |
| 1 | 1.06354996 | -0.2302075 | 2.1625865 | -0.85255100 | 0.043663295 | -0.642369744 | -1.106806113 | 0 |
| 2 | 0.09963647 | 0.1698102 | 0.7722207 | 0.32254598 | -0.946937693 | -0.003484947 | -1.571009376 | 0 |
| 3 | -0.20318663 | -1.6002222 | 0.9197952 | -2.27563510 | -1.132243447 | -0.296804827 | 1.798434125 | -2 |
| 4 | 1.64786409 | 1.0326720 | 0.9835946 | -0.59749539 | -1.025665909 | -1.045325997 | 1.224598811 | 1 |
| 5 | 0.21911119 | 0.6933385 | 0.8696091 | 0.70749139 | 0.544941715 | 0.091958416 | -1.129076589 | -0 |
| 6 | 0.58301891 | -2.3648097 | -1.2462427 | 1.61382932 | -0.003345741 | 0.799790746 | 0.876313306 | 1 |
| 7 | 0.95296339 | 1.8123840 | 0.2745364 | -0.43424121 | -0.036157537 | 1.702941952 | 1.777746545 | -0 |
| 8 | -0.67577523 | -1.2476084 | 0.4996071 | -1.39729450 | 1.905133497 | -0.362825955 | 2.107952152 | 0 |
| 9 | 0.60781505 | 0.4328491 | 1.1514827 | -0.06679411 | -1.047561539 | 0.092490208 | 0.603427389 | 1 |
| 10 | -1.06525414 | -1.3455687 | -0.8164878 | 0.26757808 | -0.178153261 | -1.730603812 | 0.420692786 | -0 |
| 11 | -0.00373073 | -0.3006000 | -1.1000735 | -0.50047446 | -0.077005365 | -0.00373073 | -0.310563130 | -0 |

Вычислим значения оценок в R и посмотрим получившиеся векторы оценок.


```
```{r}
rez1 <- apply (M , 1, function (x) (2/n)* sum (x))
rez2 <- apply (M , 1, function (x) ((n +1) /n) * max (x))
rez3 <- apply (M , 1, function (x) (2* quantile (x , c (0.5))))
```

```{r}
str(rez1)
str(rez2)
str(rez3)
```

num [1:20] -0.14 -0.238 -0.994 0.649 0.242 ...
num [1:20] 2.379 1.161 1.978 1.813 0.957 ...
num [1:20] -0.873 0.269 -0.695 1.017 0.764 ...
```

Отобразим получившиеся значения на графике:

```
```{r}
plot (rez1 , col = " red ")
lines (rez1 , col = " red")
par (new =T)
plot (rez2 , col = " blue ")
lines (rez2 , col = " blue ")
par (new =T)
plot (rez3 , col = " yellow ")
lines (rez3 , col = " yellow ")
par (new =F)
```
```



Вычислим среднеквадратическое отклонение, максимальное и минимальное значение, величину размаха:

```
```{r}
p11 <- sd(rez1)
p12 <- sd(rez2)
```

```

p13 <- sd(rez3)
```
```{r}
max1 <- max(rez1)
max2 <- max(rez2)
max3 <- max(rez2)
```
```{r}
min1 <- min(rez1)
min2 <- min(rez2)
min3 <- min(rez2)
```
```{r}
R1<-max1-min1
R2<-max2-min2
R3<-max3-min3
```

```

Для выборок объема $n=40$ и $n=160$ необходимо также вычислить оценки по трем способам. Свести параметры (минимальное и максимальное значение, величину размаха, среднеквадратическое отклонение между оценками для выборок объема 10, 40, 160) в одну таблицу. Отобразить на графике среднеквадратическое отклонение для всех оценок по всем проанализированным выборкам.

Задание на самостоятельную работу:

1. Сравнить три способа оценивания на выборках объема $n=10$, $n=40$ и $n=160$ для величин, распределенных по нормальному и экспоненциальному законам распределения. Параметры для генерирования выборок необходимо взять из таблицы 2 в соответствии с номером в списке группы.

Таблица 2 - Варианты заданий (n – порядковый номер в списке группы)

| | 1-10 | 11-20 | 21-30 |
|-----|---------------------------|------------------------------|------------------------------|
| НЗР | $m=2+2n$
$\sigma=3+3n$ | $m=10+3n$,
$\sigma=3+3n$ | $m=15+2n$,
$\sigma=3+3n$ |
| ПЗР | $\lambda=1+n$ | $\lambda=3+n$ | $\lambda=5+n$ |

- Сравнить минимальные и максимальные величины, величину размаха, среднеквадратическое отклонение между оценками для выборок объема 10,40,160 для каждого закона распределения отдельно.
- Сравнить графически среднеквадратические отклонения трех оценок для значений $n=10$, $n=40$ и $n=160$ для каждого закона распределения отдельно.
- Сделать выводы о точности найденных оценок.

Тема № 3: Проверка на нормальность распределения

Распределение можно проверить на нормальность следующими способами:

1. Графические способы

Самый простой графический способ проверки характера распределения данных – это построение гистограммы. Построить гистограмму можно используя **hist()**.

Для проверки нормальности распределения также можно воспользоваться функциями **sm.density()** и **sm.density.compare()** из пакета **sm**.

```
install.packages("sm")
```

```
library(sm)
```

```
sm.density(X, model = "Normal", xlab="Выборка", ylab="Функция плотности  
распределения")
```

2. Формальные тесты

В R реализованы практически все имеющиеся тесты на нормальность – либо в виде стандартных функций, либо в виде функций, входящих в состав подгружаемых пакетов:

ad.test() - тест Андерсона-Дарлинга;

cvm.test() - тест Крамера фон Мизеса;

lillie.test() - тест Колмогорова-Смирнова в модификации Лиллиефорса;

sf.test() - тест Шапиро-Франсия.

В общем виде проверяемую при помощи этих тестов нулевую гипотезу можно сформулировать так: “анализируемая выборка происходит из генеральной совокупности, имеющей нормальное распределение”. Если получаемая при помощи того или иного теста вероятность ошибки p оказывается меньше некоторого заранее принятого уровня значимости (например, 0.05), нулевая гипотеза отклоняется.

Рассмотрим практическое применение способов проверки на нормальность распределения в R.

Загрузим пакет **ggplot2**

```
library(ggplot2)
```


Загрузим пакет sm

```
library(sm)
```

```
## Package 'sm', version 2.2-5.4: type help(sm) for summary information
```

Загрузим данные набора diamonds


```
diamond<-diamonds
```

Выберем из набора переменную Price


```
Z<-diamond$price
```

Построим гистограмму ряда Price

```
hist(Z)
```



```
sm.density(Z, model = "Normal", xlab = "Price", ylab = "Функция плотности распределения")
```



На этом графике показана кривая плотности для эмпирических данных, позволяющая оценить, насколько правдоподобно предположение о нормальности, и в каких диапазонах анализируемой переменной наблюдаются отклонения от нормального закона распределения (доверительный интервал для нормального закона распределения показан полосой голубого цвета).

Выполним тест Колмогорова-Смирнова в модификации Лиллиефорса на проверку нормальности:

```
library(nortest)
lillie.test(X)
```

```
library(nortest)

lillie.test(Z)

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  Z
## D = 0.18467, p-value < 2.2e-16
```

Данные тест указывает на то, что нулевая гипотеза отвергается.

Задание на самостоятельную работу:

1. Выбрать самостоятельно исходные данные в виде переменной, состоящей из 20 и более наблюдений (данные должны быть реального экономического показателя, например ВВП, объем экспорта, уровень безработицы, привести ссылку на исходные данные).

Данные можно найти в следующих источниках:

1. <https://university.prognoz.ru/biu/go/main/dataportalinfo/>
 2. <https://www.kaggle.com/datasets>
 3. <http://www.gks.ru/>
 4. The R Datasets Package - <https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/00Index.html> .
2. Определить является ли распределение показателя нормальным, определить показатели статистик Колмогорова-Смирнова и Лиллиефорса. (Вставить Скриншорт результатов)
 3. На основе выполненных исследований сделать выводы о статистическом распределении показателя (симметричности, «пиковости» и т.п.), выводы о нормальности распределения показателя на основе критерия Колмогорова-Смирнова и Лиллиефорса.

Тема № 4. Изучение корреляционной зависимости двух случайных величин

Целью является исследование статистической связи двух показателей на основе расчета различных коэффициентов корреляции.

- умение вычислять коэффициент корреляции Пирсона двух случайных величин;
- умение вычислять коэффициент ранговой корреляции Спирмена и Кендалла;
- определение статистической значимости коэффициентов ранговой корреляции на основе соответствующих тестов, формирование вывода о статистической связи (о характере и силе связи) двух показателей на основании анализа коэффициентов корреляции.

Оценка корреляции двух случайных величин*

Введем две переменные X и Y.

```
X <- c (0.71, 0.17, 1.06, 3.21, 7.26, 0.24, 3.84, 1.96, 0.17, 7.83, 0.02, 0.99, 1.62, 1.15, 0.08, 1.09, 4.56, 0.14, 0.25, 0.53)
```

```
Y <- c (14.7, 6.23, 2.33, 14.7, 6.23, 0.96, 6.98, 3.7, 0.43, 3.33, 5.46, 31.63, 5.16, 8.17, 1.2, 15.46, 23.7, 5.16, 7.84, 0.23)
```

```
X <- c (0.71, 0.17, 1.06, 3.21, 7.26, 0.24, 3.84, 1.96, 0.17, 7.83, 0.02, 0.99, 1.62, 1.15, 0.08, 1.09, 4.56, 0.14, 0.25, 0.53)
```

```
Y <- c (14.7, 6.23, 2.33, 14.7, 6.23, 0.96, 6.98, 3.7, 0.43, 3.33, 5.46, 31.63, 5.16, 8.17, 1.2, 15.46, 23.7, 5.16, 7.84, 0.23)
```

```
str(X)
```

```
## num [1:20] 0.71 0.17 1.06 3.21 7.26 0.24 3.84 1.96 0.17 7.83 ...
```

```
str(Y)
```

```
## num [1:20] 14.7 6.23 2.33 14.7 6.23 0.96 6.98 3.7 0.43 3.33 ...
```

Для оценки тесноты связи необходимо обратиться к функции `cor.test()`. По умолчанию вычисляется коэффициент корреляции Пирсона при 95% доверительной вероятности.

```
cor.test(X, Y)
```

```
cor.test(X,Y)
```

```
##  
## Pearson's product-moment correlation  
##
```

```
## data: X and Y
## t = 0.49633, df = 18, p-value = 0.6257
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.3440149 0.5313920
## sample estimates:
## cor
## 0.1161946
```

Для вычисления коэффициента Спирмена при 95% доверительной вероятности в R при вызове функции `cor.test()` необходимо воспользоваться аргументом `method` со значением "spearman":

`cor.test(X, Y, method = "spearman")`

```
cor.test (X, Y, method = "spearman")

## Warning in cor.test.default(X, Y, method = "spearman"): Cannot compute
## exact p-value with ties

##
## Spearman's rank correlation rho
##
## data: X and Y
## S = 874.82, p-value = 0.1397
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
## rho
## 0.3422441
```

Пример расчета коэффициента Кендалла при 95% доверительной вероятности:

`cor.test(X, Y, method = "kendall")`

```
cor.test (X, Y, method = "kendall")

## Warning in cor.test.default(X, Y, method = "kendall"): Cannot compute exact
## p-value with ties

##
## Kendall's rank correlation tau
##
## data: X and Y
## z = 1.3005, p-value = 0.1934
## alternative hypothesis: true tau is not equal to 0
## sample estimates:
## tau
## 0.212769
```

Пример расчета коэффициента Кендалла при 99% доверительной вероятности

```
cor.test(X, Y, method = "kendall", conf.level = 0.99)
```

```
cor.test (X, Y, method = "kendall", conf.level = 0.99)

## Warning in cor.test.default(X, Y, method = "kendall", conf.level = 0.99):
## Cannot compute exact p-value with ties

##
## Kendall's rank correlation tau
##
## data:  X and Y
## z = 1.3005, p-value = 0.1934
## alternative hypothesis: true tau is not equal to 0
## sample estimates:
##      tau
## 0.212769
```

Задание на самостоятельную работу:

1. Выбрать самостоятельно исходных данные в виде переменных, состоящих из 20 и более наблюдений, между которыми предположительно есть связь (данные должны быть реального экономических показателей, например, выявить связь между уровнем безработицы и средней заработной платой в каждом регионе, привести ссылку на исходные данные)**.

Данные можно найти в следующих источниках:

1. <https://university.prognoz.ru/biu/go/main/dataportalinfo/>
 2. <https://www.kaggle.com/datasets>
 3. <http://www.gks.ru/>
 4. The R Datasets Package - <https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/00Index.html> .
2. Вычислить коэффициенты ранговой корреляции Пирсона, Спирмена и Кендалла. (Вставить Скриншорт результатов)
 3. Проверить статистическую значимость коэффициентов ранговой корреляции Спирмена и Кендалла при 95% и 99% доверительной вероятности на основе соответствующих тестов (Вставить Скриншорт результатов). Критические значения S-статистики и z-статистики при 95% и 99% доверительной вероятности определить в R.

4. Сделать выводы о силе, направлении и характере статистической связи между исследуемыми показателями.

* Мостицкий С.Э., Шитиков В.К. (2014) Статистический анализ и визуализация данных с помощью R. – Электронная книга, адрес доступа: <http://r-analytics.blogspot.com>

**Примечание: временные ряды не рассматривать.

Тема № 5. Коэффициент конкордации

Использование коэффициента конкордации для оценки согласованности мнений экспертов.

Коэффициент конкордации Кендала используется для определения взаимосвязи (согласованности) оценок экспертов. Значение коэффициента конкордации может находиться в диапазоне от 0 до 1. Если $W=0$, считается, что мнения экспертов не согласованы. Если $W=1$, то оценки экспертов полностью согласованы.

В литературе описание коэффициент конкордации Кендала, ограничивается формулами, в которых не учитываются связанные ранги, а критерий ограничивается требованием стремления W к единице, что существенно затрудняет его практическое использование. Тогда как в абсолютном выражении W может оказаться очень малым, но его значение будет статистически значимым для проверки гипотезы о равномерном распределении рангов (согласии ранжировок). Вычисление коэффициента конкордации без введения поправочных коэффициентов и проверки на статистическую значимость, может привести к существенным ошибкам.

Можно выделить 2 ограничения в использовании коэффициент конкордации Кендала:

- невозможность рассчитать согласованность мнений экспертов по каждой переменной в отдельности.
- коэффициент измеряет согласованность мнений в смысле их коррелированности, но не совпадения.

Реализация нахождения коэффициента конкордации в R:

Для примера, рассчитаем коэффициент конкордации и оценим согласованность мнений экспертов относительно необходимости включения в профиль должности торгового представителя отобранных 13 ключевых компетенций в R Studio.

1. Сформирована выборка из 4 экспертов, задачей которых являлось оценить по 5 балльной шкале необходимость включения в профиль должности торгового представителя 13 компетенций.

| Компетенции | Эксперты | | | |
|-------------------------|----------|----------|----------|----------|
| | Эксперт1 | Эксперт2 | Эксперт3 | Эксперт4 |
| Ориентация на результат | 5 | 5 | 5 | 5 |
| Организованность | 5 | 5 | 5 | 5 |
| Влияние и воздействие | 5 | 5 | 5 | 4 |
| Коммуникативность | 3 | 5 | 5 | 5 |
| Уверенность в себе | 5 | 4 | 4 | 5 |
| Управление конфликтами | 4 | 5 | 5 | 4 |
| Адаптируемость | 4 | 5 | 4 | 4 |
| Командная работа | 5 | 3 | 5 | 4 |
| Ориентация на клиента | 5 | 4 | 3 | 5 |
| Активное слушание | 4 | 4 | 5 | 4 |
| Открытость | 5 | 4 | 4 | 4 |
| Управление рисками | 5 | 4 | 4 | 4 |
| Гибкость | 4 | 3 | 5 | 4 |

Для нахождения коэффициента конкордации в R необходимо установить пакет/библиотеку **vegan** .

Функция *kendall.global* вычисляет и проверяет коэффициент согласованности между несколькими экспертами (переменными, видами) с помощью теста перестановки.

```
kendall.global(Y, group, nperm = 999, mult = "holm")
```

Функция *kendall.post* выполняет апостериорные тесты вкладов отдельных экспертов (переменных, видов) в общую согласованность их группы с помощью тестов на перестановку.

```
kendall.post(Y, group, nperm = 999, mult = "holm")
```

Если в таблице данных определены несколько групп экспертов, коэффициенты согласования (*kendall.global*) или апостериорные тесты (*kendall.post*) будут вычисляться для каждой группы отдельно.

Загрузим данные в формате **txt**.

```
> chem <- read.table(file = "cc.txt", header = TRUE)
> View(chem)
```

| | X1 | X2 | X3 | X4 |
|----|----|----|----|----|
| 1 | 5 | 5 | 5 | 5 |
| 2 | 5 | 5 | 5 | 4 |
| 3 | 3 | 5 | 5 | 4 |
| 4 | 3 | 5 | 5 | 5 |
| 5 | 5 | 4 | 4 | 5 |
| 6 | 4 | 5 | 4 | 4 |
| 7 | 5 | 3 | 5 | 4 |
| 8 | 5 | 4 | 3 | 5 |
| 9 | 4 | 4 | 5 | 4 |
| 10 | 5 | 4 | 4 | 4 |
| 11 | 5 | 4 | 4 | 4 |
| 12 | 4 | 3 | 5 | 4 |
| 13 | 4 | 5 | 4 | 5 |

Применим функцию

```
> kendall.global(chem, nperm = 999, mult = "holm")
$Concordance_analysis
      Group.1
W      0.1754120
F      0.6381804
```

```
Prob.F      0.7895410
Chi2        8.4197745
Prob.perm   0.7840000

attr(,"class")
[1] "kendall.global"
```

Полученное решение показывает, что согласованность между экспертами низкая относительно необходимости включения в профиль должности торгового представителя всех отобранных компетенций, так как значение коэффициента конкордации - 0,17. Далее необходимо выдвинуть гипотезы о значимости коэффициента конкордации и определить значим ли коэффициент.

К сожалению, коэффициент конкордации не позволяет ответить на вопрос, какие из отобранных компетенций оставить, а какие исключить. Для ответа на этот вопрос можно использовать значения коэффициента вариации.

Задание на самостоятельную работу:

- 1) Придумать пример, состоящий из 20 и более альтернатив (например, оценка инвестиционных проектов).
- 2) Выбрать шкалу оценивания и оценить выбранные альтернативы по шкале 5-7 экспертами.
- 3) Вычислить коэффициент конкордации, сделать вывод о согласованности мнений экспертов и значимости коэффициента конкордации.